



République Tunisienne
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique
Université de Tunis EL Manar
Faculté des Sciences de Tunis



Projet de fin d'année
Présenté en vue de l'obtention du Diplôme National de Licence
en Mathématiques Appliquées. : Sciences des données

Adaptation et personnalisation continue de l'entraînement avec AIMOOV

Présenté par :
Moataz Ben Trad

Encadrant académique :
M. Samir Toumi

Encadrant professionnel :
M. Mohamed Charabi

Entreprise d'accueil :
Ai Bright



Année universitaire : 2023/2024

Dédicace

Je dédie ce modeste travail à :

Mes parents,

Mon frère ainsi que sa famille,

Mes chers amis.

Moataz Ben Trad

Remerciements

Au terme de ce travail, je voudrais adresser mes sincères remerciements aux personnes qui m'ont apportées leur aide et leur support durant tout le déroulement de mon stage.

Je tiens à présenter mes remerciements les plus sincères à mon tuteur de stage monsieur Mohamed Charaabi pour avoir dirigé ce travail, pour son encadrement et sa disponibilité.

Je tiens à exprimer ma plus profonde gratitude à M. Ouael Mouelhi, fondateur d'AI BRIGHT, pour son encadrement professionnel, ses encouragements enthousiastes et ses critiques utiles sur ce travail de recherche. Ce travail n'aurait pas été aussi abouti sans ses conseils et son aide pour maintenir mon avancement dans les délais.

Je tiens tout d'abord à témoigner ma gratitude et mon respect à mon encadreur universitaire monsieur Samir Toumi, pour son encadrement, son soutien, ses conseils judicieux et ses critiques constructives, qui m'ont beaucoup aidés dans la réalisation de mon rapport.

Je profite de cette occasion pour exprimer ma sincère gratitude à toute l'équipe pédagogique et administrative de la faculté des sciences pour la qualité de l'enseignement et le haut niveau de la formation.

Enfin, je remercie les membres du jury qui nous feront l'honneur d'accepter d'évaluer ce modeste travail, en espérant qu'ils trouveront dans ce rapport les qualités attendues.

Résumé

Ce projet a été entrepris pour répondre aux exigences d'obtention d'un diplôme de fin d'études en Mathématiques Appliquées avec une spécialisation en sciences des données de la Faculté des Sciences de Tunis (FST).

L'objectif de ce projet est de créer une expérience de fitness très personnalisée et efficace, qui s'adapte dynamiquement aux besoins changeants de l'utilisateur, en utilisant des techniques d'apprentissage automatique. En exploitant des algorithmes avancés, notre système peut surveiller les séances d'entraînement, évaluer les performances et effectuer des ajustements pour la prochaine séance d'entraînement. Ce travail démontre le potentiel des techniques d'apprentissage automatique pour améliorer les expériences de fitness à domicile.

Mots clés : Apprentissage automatique, Adaptation dynamique ,Entraînement à domicile, Ajustements d'entraînement.

Table des matières

Table des figures	6
Liste des tableaux	7
Acronymes	8
Introduction générale :	9
1 Contexte général du projet :	11
Introduction	11
1.1 Présentation de l'organisme d'accueil :	11
1.1.1 AI Bright	11
1.1.2 Activités d'AI Bright :	12
1.2 Présentation du projet	13
1.2.1 Description du projet	13
1.2.2 Énoncé du problème	13
1.2.3 Étude de l'existant :	13
1.2.4 Critique de l'existence et avantages de notre solution	15
1.3 Choix des méthodologies	15
1.3.1 Étude comparative des méthodologies existantes	15
1.3.2 Présentation de la méthodologie retenue	16
Conclusion	18
2 Compréhension métier :	19
Introduction	19
2.1 Objectif métiers	19
2.2 Objectif sciences de données	20
2.3 Principes fondamentaux de l'IA	20
2.3.1 Apprentissage automatique	21
2.3.2 Apprentissage profond	21
2.4 Environnement de travail	22

2.4.1	Matériel	22
2.4.2	Logiciels	22
	Conclusion	25
3	Compréhension et préparation des données	26
	Introduction	26
3.1	Compréhension des données	26
3.1.1	Sources de données	27
3.1.2	Données de référence	28
3.2	Préparation des données	29
3.2.1	Création des données	29
3.2.2	Description de la méthode	30
3.2.3	Paramétrisation	30
3.2.4	Méthodes de simulation	32
3.2.5	Définition JSON [4]	33
3.2.6	Exemple de données générées	34
	Conclusion	36
4	Modélisation	37
	Introduction	37
4.1	Contexte théorique	37
4.1.1	L'intelligence artificielle générative [6]	37
4.1.2	L'apprentissage par renforcement [2]	38
4.1.3	L'apprentissage par renforcement et l'intelligence artificielle générative	38
4.1.4	Choix de la méthode d'apprentissage pour le projet	39
4.1.5	Choix de l'algorithme d'apprentissage par renforcement	40
4.2	Mathématiques du Q-learning	41
4.3	Exemple concret de calcul de la Q-table	42
4.3.1	Premier pas de temps	42
4.3.2	Deuxième pas de temps	43
4.3.3	Troisième pas de temps	44
4.3.4	Quatrième pas de temps	45
4.4	Modélisation du Q-learning à notre contexte	45
4.4.1	Fonctionnement de l'agent de fitness	47
4.4.2	Cas d'utilisation pour un utilisateur	48
	Conclusion	53
	Bibliographie	56

Table des figures

1.1	AI Bright Logo.	11
1.2	AIMOOV.	12
1.3	Fitbit.	14
1.4	Apple Health.	14
1.5	Google Fit.	15
1.6	Méthodologie CRISP-DM.	17
2.1	Intelligence artificielle.	20
2.2	Apprentissage automatique.	21
2.3	Apprentissage profond.	22
2.4	Python logo.	23
2.5	Google colab logo.	23
2.6	Git logo.	24
2.7	Discord logo.	24
3.1	Exemple de la structuration des exercices d'entraînement.	29
3.2	Exemple d'un profil d'utilisateur.	34
3.3	Exemple des exercices d'une séance de sport.	35
3.4	Exemple des données de fréquences cardiaque pendant une séance d'entraînement.	36
4.1	Apprentissage par renforcement.	38
4.2	Exemple d'un système de récompense simple.	41
4.3	Récompenses par séance d'entraînement.	49
4.4	Moyenne mobile des récompenses.	50
4.5	Récompense moyenne cumulative par séance d'entraînement.	51
4.6	Décroissance d'epsilon au fil des séances.	52

Liste des tableaux

1.1	Comparaison des méthodologies	16
3.1	Fréquence cardiaque par âge et condition physique pour les hommes [10]	28
3.2	Fréquence cardiaque par âge et condition physique pour les femmes [10]	29
3.3	Zones de fréquence cardiaque et leurs caractéristiques	32
4.1	Comparaison de l'apprentissage par renforcement et de l'IA générative	39

Liste des acronymes

- **CRISP-DM** : Cross Industry Standard Process for Data Mining.
- **SEMMA** : Sample, Explore, Modify, Model, Assess.
- **KDD** : Knowledge Discovery in Databases.
- **IA** : Intelligence Artificielle.
- **IAG** : Intelligence Artificielle Générative.
- **APR** : Apprentissage par Renforcement.
- **BPM** : Battements Par Minute.
- **kcal** : Kilocalories.
- **JSON** : JavaScript Object Notation.

Introduction générale :

Le domaine de la e-santé et du e-fitness a grandement bénéficié de l'évolution des technologies numériques. L'intégration rapide de l'intelligence artificielle dans ce secteur a permis de développer des applications de fitness à domicile qui sont devenues cruciales, notamment en période de pandémie. Le produit AIMOOV d'Ai Bright vise à exploiter ces technologies pour offrir une expérience de fitness sur mesure. Ce projet s'inscrit dans le contexte de l'intégration progressive des données de smartwatches et smartphones, visant à améliorer la précision et l'efficacité des entraînements à domicile.

La nouvelle version de notre produit est conçue pour utiliser les données des montres connectées et des écosystèmes comme Google Fit et Apple Health. Cependant, nous faisons face à un défi important : l'absence de données historiques suffisantes pour entraîner nos modèles d'intelligence artificielle. Pour résoudre ce problème, nous avons mis en place des méthodes de génération de données. Cette solution nous permettra d'utiliser les données réelles dès qu'elles seront disponibles, sans attendre un long délais pour réaliser la collecte. Notre but est de créer une expérience de fitness très personnalisée et efficace, qui s'adapte dynamiquement aux besoins changeants de l'utilisateur, en utilisant des techniques d'apprentissage automatique .

Nous adoptons une approche hybride combinant la simulation de données et l'apprentissage automatique pour préparer le système à l'utilisation future des données réelles. Cette méthodologie inclut le développement de modèles prédictifs et adaptatifs qui peuvent être mis à jour dynamiquement avec de nouvelles données.

Le projet couvrira le développement du modèle initial et la création d'un simulateur de données. Les livrables incluront un prototype de système, des rapports de validation de modèle, et une documentation complète sur les processus et les méthodes utilisés.

Ce rapport synthétise l'ensemble des travaux réalisés dans cette perspective. Il

est organisé en quatre chapitres comme suit :

Nous commençons par un chapitre introductif intitulé " Contexte général du projet "qui sera consacré à la présentation du cadre général du projet en décrivant l'organisme d'accueil et le choix de la méthodologie de travail appropriée.

Le chapitre suivant "Compréhension métier", qui est la première phase de la méthodologie CRISP-DM, sera consacrée à l'étude opérationnelle de notre projet en présentant les objectifs métier et les objectifs sciences des données.

Le troisième chapitre "Compréhension et préparation des données" est consacré aux phases de compréhension et de préparation des données de notre méthodologie CRISP-DM. Nous commençons par la compréhension des données, essentielle pour anticiper et résoudre les éventuelles difficultés lors de la préparation des données. Ensuite, nous passons à la préparation des données, incluant des méthodes de génération de données pour créer un ensemble de données réalistes et pertinentes pour notre projet.

Le quatrième chapitre "Modélisation" se concentre sur l'exploration des techniques d'intelligence artificielle pertinente pour notre projet. Nous comparerons différentes approches pour déterminer la meilleure méthode de modélisation. Ce chapitre inclura également une description de l'implémentation pratique de notre agent de fitness intelligent, ainsi qu'une évaluation de ses performances à travers des simulations.

Nous terminons notre travail par une conclusion générale où nous évaluons notre contribution et présentons nos idées pour les améliorations futures et les perspectives du projet.

Chapitre 1

Contexte général du projet :

Introduction

Tout d’abord, nous commençons par présenter l’entreprise d’accueil et ses activités. Ensuite, nous poursuivons avec le contexte du projet : sa description, l’énoncé du problème en annonçant notre solution et nos objectifs, ainsi que les travaux connexes. Enfin, nous présentons la méthodologie de gestion du projet.

1.1 Présentation de l’organisme d’accueil :

1.1.1 AI Bright

Fondée en 2019 et basée à Levallois-Perret, Paris, la startup AI Bright innove dans le secteur sportif en exploitant le potentiel de l’intelligence artificielle. Son objectif est de rendre l’IA accessible à tous grâce à des applications innovantes conçues pour améliorer la santé et le bien-être quotidien.



FIGURE 1.1 – AI Bright Logo.

AI Bright développe des solutions personnalisées qui utilisent des techniques avancées en apprentissage automatique pour rendre la pratique sportive plus intuitive et adaptée aux besoins individuels de ses utilisateurs. En combinant l'IA et la réalité augmentée, AI Bright propose une interface interactive qui simplifie et optimise l'entraînement. L'ambition d'AI Bright est de devenir un leader mondial dans le domaine de la vidéo intelligente, en ciblant à la fois les marchés grand public et professionnels.

1.1.2 Activités d'AI Bright :

AI Bright a développée AIMOOV, une caméra intelligente qui offre les avantages d'un entraîneur à domicile, avec une différence notable : votre coach est l'Intelligence Artificielle (IA). AIMOOV est conçu pour être le plus petit instructeur de gym du monde. Cette caméra intelligente vous aide à vous entraîner à la maison en suivant vos progrès et en corrigeant les postures ou la forme lorsque nécessaires. Elle fonctionne en temps réel et se synchronise avec vos applications de suivi de santé



FIGURE 1.2 – AIMOOV.

[1]

AI Bright intègre plusieurs technologies avancées pour enrichir et optimiser cette caméra intelligente :

Vision par ordinateur : Permet à la caméra de classifier et de régresser des images et vidéos, offrant ainsi des fonctionnalités avancées en temps réel.

Reconnaissance vocale : Cette technologie permet aux utilisateurs d'interagir facilement avec AIMOOV, facilitant son utilisation par une grande variété de

publics.

Réalité augmentée : Enrichit l'environnement immédiat de l'utilisateur avec des objets virtuels intégrés de manière réaliste, ce qui améliore l'engagement.

Animation 3D : Peut transformer n'importe quelle vidéo en une animation 3D, grâce à l'apprentissage profond, permettant des analyses et des visualisations dynamiques.

Ces technologies ne se limitent pas à enrichir l'expérience de l'utilisateur, elles transforment AIMOOV en un outil robuste et polyvalent pour le fitness à domicile.

1.2 Présentation du projet

1.2.1 Description du projet

En 2023, AI Bright a lancé AIMOOV, une caméra intelligente conçue pour personnaliser et optimiser l'expérience de fitness à domicile. Ce dispositif intégrera de façon sécurisée des données provenant de Google Fit et Apple Health, y compris des indicateurs physiologiques et d'activité tels que le rythme cardiaque, le nombre de pas et les activités externes. Ces données seront collectées en temps réel via des dispositifs connectés, tels que les smartphones et les montres connectées, avec le consentement de l'utilisateur. Dans ce contexte, notre objectif sera de fournir une expérience de fitness hautement personnalisée et efficace, adaptant dynamiquement chaque session aux besoins évolutifs de l'utilisateur, en utilisant des techniques d'apprentissage automatique.

1.2.2 Énoncé du problème

La nouvelle version de notre produit, conçue pour intégrer les données de smartwatches et des écosystèmes comme Google Fit et Apple Health, est confrontée à un défi majeur : le manque de données historiques pour entraîner efficacement nos modèles d'intelligence artificielle. Ce déficit rend difficile la création immédiate d'une expérience de fitness personnalisée et efficace. Notre objectif est de développer des solutions qui permettent d'utiliser des techniques d'apprentissage automatique pour adapter dynamiquement chaque session de fitness aux besoins évolutifs de chaque utilisateur, sans avoir à attendre une longue période de collecte de données initiale.

1.2.3 Étude de l'existant :

L'étude de l'existant est une étape préliminaire avant de se lancer dans tout projet. Elle nous donne un aperçu de la pertinence du projet, de sa faisabilité et de

sa durabilité.

Fitbit

Fitbit propose des montres intelligentes et des bracelets de fitness qui collectent des données telles que le rythme cardiaque, les pas, la qualité du sommeil, et les calories brûlées. L'IA est utilisée pour analyser ces données et fournir des recommandations personnalisées pour améliorer la santé et la forme physique des utilisateurs.



FIGURE 1.3 – Fitbit.

Apple

Avec l'Apple watch, Apple offre une expérience de fitness intégrée qui inclut le suivi des activités, le coaching de santé, et la surveillance médicale. L'Apple Watch utilise l'IA pour interpréter les données de santé et d'activité, offrant des rappels personnalisés pour bouger ou s'entraîner.




FIGURE 1.4 – Apple Health.

Google

Google, à travers ses wear OS et ses intégrations avec Google Fit, permet aux utilisateurs de suivre divers indicateurs de santé et de fitness. Google Fit utilise des algorithmes d'IA pour fournir des insights basés sur les données collectées, comme les minutes d'activité et les points cardio. Ces fonctionnalités aident les utilisateurs à comprendre leur niveau d'activité physique et à recevoir des conseils personnalisés pour améliorer leur condition physique et leur bien-être.



FIGURE 1.5 – Google Fit.

1.2.4 Critique de l'existence et avantages de notre solution

Bien que les produits de Fitbit, Apple et Google offrent des fonctionnalités avancées pour le suivi de la santé et du fitness, malgré la collecte d'une grande variété de données, leur utilisation pour personnaliser les entraînements en temps réel reste généralement superficielle. Les programmes proposés sont souvent standards et ne s'adaptent pas dynamiquement aux performances et aux progrès individuels de l'utilisateur au cours d'une session. En contraste, notre produit se distingue par son accès direct à ces données, ainsi que par sa capacité à offrir des entraînements personnalisés selon l'objectif et la condition physique de l'utilisateur. Grâce à l'intégration de notre caméra intelligente, non seulement nous suivons les données physiologiques de l'utilisateur en temps réel, mais nous corrigeons également les mouvements de l'utilisateur pendant ses exercices. Cette fonctionnalité de correction en temps réel permet une adaptation et une amélioration immédiates, guidant l'utilisateur de manière efficace pour atteindre ses objectifs de fitness de manière plus précise et engagée.

1.3 Choix des méthodologies

Il existe plusieurs méthodologies de gestion qui peuvent être appliquées aux projets de sciences de données. Les plus courantes sont CRISP-DM [3], SEMMA [11], KDD [7]. Dans cet article, nous allons les comparer afin de choisir la méthodologie la plus adéquate

1.3.1 Étude comparative des méthodologies existantes

Nous présentons dans cette sous-section une comparaison entre les méthodologies CRISPDM, SEMMA et KDD

Méthodologies	Avantages	Inconvénients
CRISP-DM	Applicable à tous les types de projets Big data. Modèle hiérarchique. Adopte une approche itérative et cyclique. La séquence des phases n'est pas stricte. Peut être mis en œuvre sans beaucoup de formation, de changement de rôle organisationnel ou de controverse.	Nécessite une documentation plus approfondie. Suppose de façon implicite que son utilisateur est une seule personne ou une petite équipe et ignore la coordination du travail en équipe.
SEMMA	Facilite l'application des techniques d'exploration statistique des données et de visualisation par les analystes de données, ainsi que la sélection et la transformation des prédicteurs les plus significatifs. Assure l'exactitude des résultats du modèle utilisé.	Ignore la phase de compréhension de métier. Ne couvre pas les derniers aspects de la phase de déploiement.
KDD	Le processus est interactif et itératif. Peut gérer de grandes masses de données. Description technique approfondie de l'analyse des données.	Tend à oublier des aspects importants dans le business. Il est parfois nécessaire de faire des boucles de retours non nécessaires.

TABLE 1.1 – Comparaison des méthodologies

1.3.2 Présentation de la méthodologie retenue

Après avoir comparé les différentes méthodologies, nous avons finalement opté pour la méthodologie CRISP-DM. Cette méthode, agile et itérative, est la plus appropriée pour notre projet car elle correspond mieux à nos besoins en termes de construction et de déroulement des opérations. La méthode CRISP, connue sous le nom de CRISP-DM, a été développée par IBM dans les années 1960 pour les

projets de data mining. Aujourd'hui, c'est l'une des méthodes les plus performantes pour les projets de science des données. Elle se décompose en 6 étapes allant de la compréhension du problème métier au déploiement et la mise en production :

1- Compréhension du problème métier :

Cette étape a pour objectif d'obtenir une vue d'ensemble de l'activité du client.

2- Compréhension des données :

Cette étape vise à identifier les données nécessaires pour répondre à vos besoins.

3- Prétraitement des données :

Cette étape sert à préparer les données dans un format adéquat.

4- Modélisation :

Cette étape sert concevoir des modèles de données/solutions pour répondre aux besoins.

5- Evaluation :

Cette étape permet de tester les résultats par rapport aux objectifs du projet.

6- Déploiement :

Cette étape vise à déployer la solution et/ou les résultats dans une application




FIGURE 1.6 – Méthodologie CRISP-DM.

Conclusion

Après avoir présenté le projet et l'organisation hôte, nous suivrons dans les chapitres suivants les étapes de la méthodologie CRISP-DM adoptée et de la compréhension métier au déploiement.

Chapitre 2

Compréhension métier :

Introduction

La première étape de notre méthodologie consiste à comprendre ce que nous voulons réaliser d'un point de vue opérationnel ainsi que les objectifs en matière de science des données.

2.1 Objectif métiers

Dans cette section, nous définissons les objectifs métiers de notre projet, qui sont cruciaux pour assurer une compréhension approfondie des exigences commerciales et de l'impact potentiel de notre solution. AI Bright vise à révolutionner le fitness à domicile en lançant une solution de fitness intelligente et interactive. L'objectif de ce projet est de fournir une expérience utilisateur enrichie et personnalisée grâce à l'intégration intelligente des données de santé provenant de divers dispositifs connectés.

Le succès de ce projet sera mesuré par les critères suivants :

Lancement réussi sur le marché : Mise en place et adoption d'une solution de fitness à domicile qui utilise l'intelligence artificielle pour offrir une personnalisation sans précédent.

Satisfaction des utilisateurs : Amélioration notable de l'expérience utilisateur, avec des retours positifs quant à l'efficacité et la personnalisation des sessions d'entraînement.

Intégration des données de santé : Capacité à synchroniser de manière sécurisée et efficace les données provenant des écosystèmes tels que Google Fit et Apple Health, augmentant ainsi la valeur ajoutée pour l'utilisateur.

2.2 Objectif sciences de données

Afin d'atteindre les objectifs métiers cités ci-dessus,

Simulation de données : Développer des méthodes pour générer ou simuler des données qui compensent le manque de données historiques. Cela permettra une mise en service rapide des modèles d'IA sans attendre la collecte prolongée de données, garantissant ainsi une amélioration continue et une personnalisation basée sur des scénarios réalistes.

Optimisation des objectifs de fitness : Utiliser les données pour aider les utilisateurs à atteindre leurs objectifs de fitness de manière plus efficace. Le modèle analysera les tendances des données d'entraînement et des dispositifs connectés pour proposer des ajustements dynamiques qui maximisent les résultats des utilisateurs en fonction de leurs objectifs spécifiques.

2.3 Principes fondamentaux de l'IA

L'intelligence artificielle (IA) est un domaine de l'informatique qui vise à créer des machines ou des logiciels capables d'exécuter des tâches qui, lorsqu'elles sont accomplies par des êtres humains, nécessitent de l'intelligence. Ces tâches peuvent inclure la reconnaissance vocale, la compréhension du langage naturel, la résolution de problèmes, la prise de décision, l'apprentissage, et l'adaptation à de nouvelles situations.




FIGURE 2.1 – Intelligence artificielle.

2.3.1 Apprentissage automatique

L'apprentissage automatique englobe diverses méthodes par lesquelles les machines apprennent à partir de données pour effectuer des tâches spécifiques. Il peut être classé principalement en trois types : supervisé, non supervisé, et par renforcement. L'apprentissage supervisé implique des modèles qui apprennent à partir de données étiquetées pour prédire des résultats, largement utilisés pour la classification et la régression. L'apprentissage non supervisé, en revanche, utilise des données non étiquetées pour découvrir les structures sous-jacentes ou les groupements dans les données, idéal pour la segmentation de marché ou la détection d'anomalies. L'apprentissage par renforcement se concentre sur la prise de décisions séquentielles, où un agent apprend à atteindre un objectif dans un environnement incertain en maximisant les récompenses cumulées.

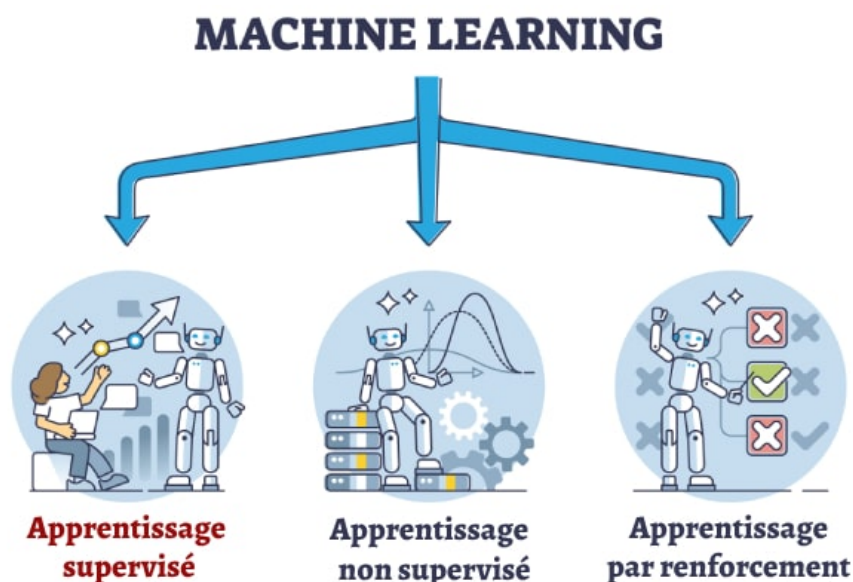


FIGURE 2.2 – Apprentissage automatique.

2.3.2 Apprentissage profond

L'apprentissage profond est une sous-catégorie de l'apprentissage automatique basée sur des réseaux de neurones artificiels avec de nombreuses couches, ou "profondes". Ces réseaux sont capables de capturer des relations complexes dans de grandes quantités de données grâce à leur architecture hiérarchique. Chaque couche de neurones extrait et transmet des caractéristiques de plus en plus abstraites des données à la couche suivante, rendant ces modèles extrêmement efficaces pour des tâches telles que la reconnaissance d'images, la traduction automatique, et la

conduite autonome. L'importance des couches cachées réside dans leur capacité à transformer les entrées de manière non linéaire, permettant ainsi une modélisation complexe et nuancée des relations entre les caractéristiques des données.




FIGURE 2.3 – Apprentissage profond.

2.4 Environnement de travail

2.4.1 Matériel

Pour notre projet, nous utilisons un Victus doté d'une mémoire RAM de 32 GO. Le processeur utilisé est un AMD Ryzen™ 5-5600H avec une carte graphique NVIDIA® GeForce® GTX 1650 4 GB GDDR6 et un disque dur SSD M.2 TLC NVMe™ PCIe® Gen 3.0 x4 de 512 GB.

2.4.2 Logiciels

Notre travail est réalisé sous le système d'exploitation Windows 11. Pour notre projet, nous utilisons :

Python [15]

La partie modélisation est écrite en Python. C'est un langage de programmation interprété, orienté objet et de haut niveau. Python est largement apprécié pour sa syntaxe simple et lisible, ce qui facilite l'écriture et la maintenance du code. Il vise à aider les programmeurs à écrire un code clair et logique pour des projets de petite et grande envergure. Grâce à sa vaste bibliothèque standard et à ses nombreux modules tiers, Python est particulièrement adapté pour le développement

rapide de prototypes, l'analyse de données, le calcul scientifique, l'apprentissage automatique et le développement web. Sa communauté active et ses ressources abondantes en font un choix privilégié pour les développeurs et les chercheurs dans divers domaines.



FIGURE 2.4 – Python logo.

Google Colab [14]

Google Colab, ou Colaboratory, est un service cloud proposé par Google, principalement en accès libre. Il est basé sur Jupyter Notebook et est destiné à la formation et à la recherche dans le domaine de l'apprentissage. Cette plateforme permet de développer et d'entraîner des modèles d'apprentissage automatique directement dans le cloud, sans avoir besoin d'installer les bibliothèques nécessaires ou autres logiciels sur son propre ordinateur. Google Colab offre également des GPU et TPU gratuits, facilitant le traitement de grandes quantités de données et l'entraînement de modèles complexes. Grâce à son intégration avec Google Drive, il est facile de sauvegarder et de partager des notebooks, ce qui en fait un outil puissant et accessible pour les chercheurs, les étudiants et les professionnels.



FIGURE 2.5 – Google colab logo.

Git [13]

C'est un système de contrôle de version distribué gratuit et open source conçu pour gérer des projets allant de petits à très grands avec rapidité et efficacité. Git permet et encourage à avoir plusieurs branches locales qui peuvent être totalement indépendantes les unes des autres. La création, la fusion et la suppression de ces lignes de développement se font en quelques secondes.



FIGURE 2.6 – Git logo.

Discord [12]

Pour la communication collaborative, nous utilisons Discord, une plateforme qui permet des échanges textuels, vocaux et vidéo en temps réel. Elle nous aide à maintenir une communication fluide et régulière entre les membres de l'équipe, essentielle pour la coordination de nos activités de développement et pour les réunions d'avancement du projet. Discord offre également des fonctionnalités de partage d'écran et de groupes privés, ce qui renforce notre efficacité collaborative.



FIGURE 2.7 – Discord logo.

Conclusion

Ce chapitre a été consacré à la compréhension métier, qui inclut les objectifs métier et les objectifs de data mining que nous cherchons à atteindre.

Chapitre 3

Compréhension et préparation des données

Introduction

Le présent chapitre est consacré aux phases de compréhension et de préparation des données de notre méthodologie CRISP-DM. Nous commençons par comprendre les données, ce qui est d'une importance vitale car cela permet d'éviter des problèmes inattendus lors de la phase suivante. Ensuite, nous passons à la préparation des données qui implique plusieurs étapes distinctes, y compris l'utilisation de méthodes de génération de données pour créer un ensemble réaliste et pertinent. Ces données générées nous permettent d'effectuer toutes les transformations nécessaires pour obtenir notre ensemble de données final, qui sera ensuite utilisé dans la phase de modélisation.

3.1 Compréhension des données

Dans cette section, nous allons détailler notre approche pour comprendre les données nécessaires à notre projet. Étant donné que nous n'avons pas accès aux vraies données pour le moment, mais que la future version de notre produit est conçue pour intégrer les données des montres connectées et des écosystèmes comme Google Fit et Apple Health, nous utiliserons des méthodes de simulation pour créer un ensemble de données réalistes. Cette démarche est essentielle pour entraîner notre modèle d'apprentissage automatique et garantir que notre solution puisse s'adapter efficacement une fois les données réelles disponibles.

3.1.1 Sources de données

Données d'entraînement

Description : Les données d'entraînement, enregistrées en temps réel par la caméra intelligente, incluent les informations personnelles et les détails spécifiques de chaque session d'exercice. Elles comprennent :

- Identifiant : Un identifiant unique pour chaque utilisateur.
- Informations démographiques : Âge, Sexe, Poids, Taille.
- Détails de l'exercice : Durée pour chaque type d'exercice, nombre de répétitions, nombre d'erreurs pour chaque exercice par séance.
- Objectifs de l'entraînement : Type d'objectif de l'utilisateur (force, perte de poids, etc.).

Données des montres connectées

Description : Les données collectées via les montres connectées fournissent des insights physiologiques et sur l'activité de l'utilisateur, incluant :

- Rythme cardiaque (bpm)
- Nombre de pas (nombre total)
- Calories brûlées (kcal)
- Taux d'oxygène dans le sang (SpO2, %)
- Température du corps (°C ou °F)
- Analyse du sommeil (durée totale et phases de sommeil)

Remarque : Les mesures et la variété des données peuvent varier selon la marque de la montre connectée et nécessitent l'autorisation explicite de l'utilisateur pour être collectées et utilisées.

Données des smartphones

Description : Les smartphones, via les écosystèmes tels que Apple Health et Google Fit, fournissent des données complémentaires qui enrichissent le profil de santé de l'utilisateur :

- Données agrégées de santé et d'activité collectées par les applications de santé.

Remarque : L'accès à ces données nécessite également l'autorisation de l'utilisateur, garantissant ainsi la conformité avec les normes de confidentialité et de protection des données.

3.1.2 Données de référence

Nous avons choisi d'utiliser des tableaux de fréquences cardiaques au repos en fonction de l'âge et du niveau de condition physique pour les hommes et les femmes en nous basant sur des études et des publications scientifiques reconnues. Des données d'entraînement pour créer des programmes d'entraînement similaires au nôtre.

Fréquence cardiaque au repos selon l'âge et la condition physique

Ces tableaux présentent les plages de fréquences cardiaques au repos en fonction de l'âge et du niveau de condition physique pour les hommes et les femmes. Chaque ligne du tableau correspond à une catégorie de condition physique, et les colonnes indiquent les plages de fréquences cardiaques pour différentes tranches d'âge.

TABLE 3.1 – Fréquence cardiaque par âge et condition physique pour les hommes [10]

Homme / Condition physique	18-25 ans	26-35 ans	36-45 ans	46-55 ans	56-65 ans	65+ ans
Athlète	49-55	49-54	50-56	50-57	51-56	50-55
Excellente	56-61	55-61	57-62	58-63	57-61	56-61
Bonne	62-65	62-65	63-66	64-67	62-67	62-65
Au-dessus de la moyenne	66-69	66-70	67-70	68-71	68-71	66-69
Moyenne	70-73	71-74	71-75	72-76	72-75	70-73
En dessous de la moyenne	74-81	75-81	76-82	77-83	76-81	74-79
Mauvaise	82+	82+	83+	84+	82+	80+

TABLE 3.2 – Fréquence cardiaque par âge et condition physique pour les femmes [10]

Femme / Condition physique	18-25 ans	26-35 ans	36-45 ans	46-55 ans	56-65 ans	65+ ans
Athlète	56-60	54-59	54-59	54-60	54-59	54-59
Excellente	61-65	60-64	60-64	61-65	60-64	60-64
Bonne	66-69	65-68	65-69	66-69	65-68	65-68
Au-dessus de la moyenne	70-73	69-72	70-73	70-73	69-73	69-72
Moyenne	74-78	73-76	74-78	74-77	74-77	73-76
En dessous de la moyenne	79-84	77-82	79-84	78-83	78-83	77-84
Mauvaise	85+	83+	85+	84+	84+	84+

Données d'entraînement

Dans notre projet, nous avons développé une base de connaissances structurée pour une variété d'exercices physiques, guidant la simulation de données d'entraînement. Cette base est organisée par niveaux de compétence — débutant, intermédiaire et avancé — avec des directives spécifiques pour chaque niveau, incluant des recommandations pour la durée et l'intensité des exercices.

```
exercise_params = {
    'Squat': {'debutant': (6, 16), 'intermediaire': (16, 28), 'sportif': (28, 50), 'MET': 3.5},
    'Push-up': {'debutant': (2, 14), 'intermediaire': (14, 24), 'sportif': (24, 50), 'MET': 8.0},
    'Jumping Jack': {'debutant': (10, 30), 'intermediaire': (30, 50), 'sportif': (50, 60), 'MET': 6.0},
    'Situps': {'debutant': (3, 8), 'intermediaire': (8, 14), 'sportif': (14, 28), 'MET': 7.0},
    'V-up': {'debutant': (2, 10), 'intermediaire': (10, 26), 'sportif': (28, 52), 'MET': 4.5},
    ...
}
```

FIGURE 3.1 – Exemple de la structuration des exercices d'entraînement.

3.2 Préparation des données

3.2.1 Création des données

Nous avons choisi de générer des données pour plusieurs raisons cruciales. D'abord, cela nous permet de contourner le manque de données historiques, facilitant ainsi l'entraînement initial de nos modèles d'apprentissage automatique. Ensuite, la génération de données nous permet de continuer à améliorer notre système, même

sans nouvelles données utilisateur, ce qui est essentiel pour maintenir la pertinence et l'efficacité de notre solution de fitness personnalisée.

3.2.2 Description de la méthode

Nos données sources sont nombreuses, cependant, lors de la génération des données, il n'a pas été possible de produire l'intégralité des données sources. Après des recherches approfondies, il a été déterminé qu'il était possible de simuler certaines de ces données, ce qui a été mis en œuvre pour pallier cette limitation.

La méthode de génération de données est conçue pour simuler des profils d'utilisateurs, incluant des informations démographiques, des objectifs de remise en forme, et des données de fréquence cardiaque en fonction de l'âge, du sexe et du niveau de forme physique. Elle génère également des sessions d'entraînement détaillées en proposant des exercices spécifiques, des répétitions et des erreurs, ainsi que des données de fréquence cardiaque associées. Tous ces éléments seront enregistrés dans un fichier JSON.

3.2.3 Paramétrisation

Dans notre approche pour optimiser les programmes d'entraînement personnalisés, nous intégrons plusieurs paramètres cruciaux tels que les données démographiques, la fréquence cardiaque et les objectifs de remise en forme. Ces éléments sont essentiels pour comprendre chaque utilisateur et pour concevoir des programmes qui sont non seulement efficaces mais aussi adaptés à leurs besoins spécifiques.

Données démographiques

Les utilisateurs sont des hommes et des femmes ayant un âge compris entre 18 et 75 ans, un poids entre 50 et 120 kg, et un niveau de forme physique variant de "Mauvaise" à "Athlète".

Fréquence cardiaque au repos

La fréquence cardiaque au repos varie en fonction de l'âge, du sexe et du niveau de forme physique, selon des plages définies.

Objectifs de remise en forme

Les objectifs incluent la force, la perte de poids et le maintien général.

Sessions d'entraînement

Les sessions d'entraînement comprennent des exercices avec des répétitions, l'identification des erreurs majeures et mineures, et des calories brûlées estimées pour chaque exercice d'entraînement.

Formule pour estimer les calories brûlées

La formule pour estimer les calories brûlées pendant l'exercice est la suivante :

$$\text{Calories brûlées} = \text{MET} \times \text{Poids corporel en kg} \times \text{Durée de l'exercice en heures}$$

où MET est le coefficient métabolique de l'exercice, qui indique combien de fois l'activité est plus intense que le repos.

Fréquence cardiaque pendant l'entraînement

La fréquence cardiaque pendant l'entraînement est calculée en utilisant la réserve de fréquence cardiaque et l'intensité d'exercice, que l'on peut extraire du MET. La formule de Karvonen est utilisée pour déterminer la zone d'entraînement[16] :

$$\text{Zone d'entraînement} = (\text{FC}_{\text{max}} - \text{FC}_{\text{repos}}) \times \left(\frac{\% \text{ d'intensité}}{100} \right) + \text{FC}_{\text{repos}}$$

- **Fréquence cardiaque maximale**
- **Fréquence cardiaque au repos**
- **% d'intensité** : Le pourcentage d'intensité représente le niveau d'effort par rapport à la fréquence cardiaque maximale.
- **Zone d'entraînement** : La zone d'entraînement est la fréquence cardiaque cible que vous devez atteindre pour obtenir les bénéfices spécifiques d'une séance d'exercice.

Pour la formule de la fréquence cardiaque maximale (FCM)[5] :

$$\text{FCM} = 220 - \text{âge}$$

Exemple

Si votre fréquence cardiaque maximale est de 190 battements par minute, votre fréquence cardiaque au repos est de 60 battements par minute, et vous souhaitez vous entraîner à 70% de votre intensité maximale, alors :

Zone d'entraînement = $(190 - 60) \times 0.70 + 60 = 130 \times 0.70 + 60 = 91 + 60 = 151$ bpm

Ainsi, votre fréquence cardiaque cible pour une séance d'entraînement à 70% d'intensité serait de 151 battements par minute.

Ce tableau détaille les différentes zones d'intensité d'exercice, s'étendant de l'échauffement à l'effort maximal. Chacune de ces zones est caractérisée par des noms alternatifs, le niveau d'intensité, le pourcentage de la fréquence cardiaque maximale atteinte, et la principale source d'énergie mobilisée durant l'effort. Comprendre ces zones est crucial pour optimiser les programmes d'entraînement selon les objectifs spécifiques de chaque utilisateur[16].

Zone	Autres noms	Niveau d'intensité	% de la fréquence cardiaque maximale	Source d'énergie
Zone 1	Échauffement, récupération, facile.	Modéré-bas.	50% à 60%	Graisses
Zone 2	Aérobic, endurance, base, léger.	Modéré.	60% à 70%	Graisses
Zone 3	Tempo, seuil, cardio, modéré.	Modéré-haut.	70% à 80%	Graisses, glucides et protéines
Zone 4	Seuil de lactate, limite, difficile.	Élevé.	80% à 90%	Glucides et protéines
Zone 5	Anaérobie, V02 max, pic, maximum.	Très élevé.	90% à 100%	Glucides et protéines

TABLE 3.3 – Zones de fréquence cardiaque et leurs caractéristiques

3.2.4 Méthodes de simulation

Dans cette section, nous avons programmé les fonctions nécessaires pour simuler les données de nos utilisateurs, comprenant la génération des profils démographiques, des sessions d'entraînement, et des données de fréquence cardiaque durant l'exercice.

Génération des données démographiques

Nous créons des profils utilisateurs complets qui reflètent une variété démographique réaliste de la population générale. Chaque profil comprend des informations

essentielles telles que l'âge, le sexe, le poids et le niveau de forme physique. Ces données sont générées de manière aléatoire mais restent dans des plages réalistes. De plus, la fréquence cardiaque au repos est calculée en fonction de l'âge, du sexe et du niveau de forme physique pour correspondre aux plages spécifiques mentionnées dans les données de référence.

Simulation des sessions d'entraînement

Nous simulons des sessions d'entraînement personnalisées en fonction des objectifs et du niveau de forme physique de chaque utilisateur. Ces simulations incluent la planification des types d'exercices, le nombre de répétitions et l'identification des erreurs potentielles. Nous estimons également les calories brûlées durant chaque session en utilisant des coefficients qui représentent l'intensité des exercices.

Fréquence cardiaque durant l'entraînement

Nous simulerons la fréquence cardiaque de l'utilisateur pendant l'entraînement pour ajuster et personnaliser l'intensité des exercices. Cette simulation utilise la formule de Karvonen, un outil précis pour établir les zones cibles de fréquence cardiaque basées sur la fréquence cardiaque au repos et la fréquence cardiaque maximale estimée de l'utilisateur.

Génération des données pour une période du temps :

Nous générons un ensemble de données complet sur une période du temps pour plusieurs utilisateurs. Chaque jour, des profils sont mis à jour avec de nouvelles informations sur l'activité physique et la santé cardiovasculaire de l'utilisateur. Ces données incluent non seulement les sessions d'entraînement mais aussi des évaluations quotidiennes de la fréquence cardiaque. En outre, nous ajustons le niveau de forme physique de chaque utilisateur basé sur leur performance au fil du mois, permettant une personnalisation et une adaptation continues du programme d'entraînement.

3.2.5 Définition JSON [4]

Un fichier JSON (JavaScript Object Notation) est un format de fichier léger utilisé pour stocker et transporter des données. Il est facilement lisible par les humains et peut être interprété par de nombreux langages de programmation, ce qui le rend idéal pour l'échange de données entre applications et serveurs. Les données dans un fichier JSON sont organisées en paires clé-valeur et peuvent également inclure des tableaux et des objets imbriqués.

Dans notre cas, il est utilisé pour que chaque profil ait son propre fichier, facilitant ainsi la gestion individuelle des informations utilisateur.

3.2.6 Exemple de données générées

Données démographiques :

Cette structure JSON représente le profil d'un utilisateur avec des informations de base telles que l'identifiant, l'objectif, l'âge, le sexe, le poids, le niveau de forme physique et la fréquence cardiaque au repos.

```
{
  "Profile": {
    "user_id": 197645813,
    "goal": "strength",
    "age": 50,
    "sex": "female",
    "weight": 82,
    "fitness_level": "Excellente",
    "resting_heart_rate": 61
  },
}
```

FIGURE 3.2 – Exemple d'un profil d'utilisateur.

Sessions d'entraînement

Ceci représente les données d'une séance d'entraînement avec des informations sur la date, la durée (en secondes) de chaque exercice, l'exercice réalisé, les erreurs majeures et mineures, le nombre de répétitions et les calories brûlées pour chaque exercice.

```
"training_data": [
  {
    "date": "2024-01-01",
    "duration": 60,
    "exerciseId": "Leg Raises",
    "majErrors": 0,
    "minErrors": 5,
    "reps": 27,
    "calories": 43
  },
  {
    "date": "2024-01-01",
    "duration": 60,
    "exerciseId": "High Knees",
    "majErrors": 0,
    "minErrors": 3,
    "reps": 69,
    "calories": 49
  },
],
```

FIGURE 3.3 – Exemple des exercices d’une séance de sport.

Fréquence cardiaque durant l’entraînement :

La courbe ci-dessous représente la fréquence cardiaque de l’utilisateur pendant une session d’entraînement de 15 minutes.

On observe une variation significative de la fréquence cardiaque, démarrant à un niveau plus bas et augmentant progressivement à mesure que l’intensité de l’entraînement s’accroît. Grâce à la formule de Karvonen, nous parvenons à adapter précisément l’intensité des exercices pour atteindre les zones cibles de fréquence cardiaque de l’utilisateur. Les pics indiquent les moments de plus grande intensité, tandis que les descentes reflètent les périodes de repos ou d’activité moins intense.




FIGURE 3.4 – Exemple des données de fréquences cardiaque pendant une séance d’entraînement.

L’utilisation des méthodes décrites dans ce chapitre nous permet de générer des données simulées pour une variété d’utilisateurs, offrant ainsi une richesse de scénarios pour tester et améliorer notre modèle. Cette approche nous autorise à entraîner efficacement notre modèle d’apprentissage automatique sans dépendre de la disponibilité de données historiques. Grâce à ces techniques, nous pouvons non seulement accélérer le développement de notre solution mais également garantir sa robustesse et son adaptabilité aux besoins des utilisateurs dès son déploiement.

Conclusion

Dans ce chapitre, nous avons présenté les phases les plus importantes de notre projet qui consistent à comprendre nos données, à les explorer, puis à les préparer pour les étapes suivantes. Maintenant que les données sont prêtes, nous passerons à la phase principale de notre méthodologie CRISP-DM lors de ce stage, à savoir la modélisation.

Chapitre 4

Modélisation

Introduction

Le présent chapitre est consacré à la phase de modélisation. Nous allons explorer différentes techniques d'intelligence artificielle en comparant l'apprentissage par renforcement et l'intelligence artificielle générative. Ensuite, nous passerons à la modélisation mathématique.

L'objectif est de développer un agent de fitness capable d'optimiser et de personnaliser les séances d'entraînement des utilisateurs.

4.1 Contexte théorique

Dans cette section, nous explorons des techniques d'intelligence artificielle telles que l'apprentissage par renforcement et l'intelligence artificielle générative pour évaluer leur pertinence et choisir celle qui répond le mieux à nos besoins.

4.1.1 L'intelligence artificielle générative [6]

L'intelligence artificielle générative, souvent abrégée en IA générative, désigne les modèles d'intelligence artificielle qui sont capables de générer de nouvelles données qui ressemblent à des données réelles. Ces modèles apprennent à partir d'un ensemble de données existant pour produire de nouveaux exemples qui peuvent être indiscernables des originaux pour les humains. Les applications courantes incluent la génération de texte, d'images, de musique, et de vidéos. Ces technologies sont souvent utilisées pour innover dans des domaines créatifs, pour améliorer la réalité virtuelle, ou pour créer des simulations de données pour l'entraînement d'autres modèles d'IA.

4.1.2 L'apprentissage par renforcement [2]

L'apprentissage par renforcement est une méthode d'apprentissage automatique où un agent apprend à prendre des décisions en interagissant avec un environnement. L'agent exécute des actions et reçoit des récompenses ou des pénalités sous forme de signaux de retour selon la pertinence de ses actions vis-à-vis de l'objectif à atteindre. L'objectif de l'agent est d'apprendre à maximiser la somme des récompenses futures en découvrant quelles actions mènent aux meilleurs résultats à long terme. Cette méthode est largement utilisée dans divers domaines tels que les jeux, la robotique, l'optimisation de systèmes et les applications où la prise de décision séquentielle est cruciale.




FIGURE 4.1 – Apprentissage par renforcement.

4.1.3 L'apprentissage par renforcement et l'intelligence artificielle générative

Explorons les distinctions et complémentarités entre l'apprentissage par renforcement et l'intelligence artificielle générative pour mieux comprendre leurs applications spécifiques et leurs avantages respectifs :

Point clé	Apprentissage par renforcement (APR)	Intelligence artificielle générative (IAG)
Méthode d'apprentissage	Apprend à partir d'un système de récompenses, améliorant continuellement la précision de classification	N'apprend pas à partir des interactions ; utilise plutôt des méthodes statistiques pour générer de nouveaux échantillons de données qui imitent les distributions de données réelles.
Adaptation au comportement de l'utilisateur	Apprend et s'adapte aux nouveaux modèles de comportement de l'utilisateur au fil du temps grâce à des essais et des erreurs.	Bien qu'il ne classe pas directement, il peut être adapté pour générer des données utilisateur avec différents profils, se concentre sur la génération de données qui peuvent être statiques à moins d'être reformées ou modifiées.
Interaction en temps réel	Idéal pour les environnements nécessitant une prise de décision et une adaptation en temps réel basées sur les interactions des utilisateurs.	Non adapté aux ajustements d'interaction en temps réel ; mieux utilisé pour les scénarios de pré-formation.
Efficacité des données	Peut être gourmand en données dans l'environnement de simulation.	Très efficace dans la création de données.
Applicabilité	Peut être utilisé pour diverses tâches de classification des utilisateurs au-delà de l'environnement simulé spécifique.	Les données générées sont les plus utiles pour les tâches similaires aux paramètres de génération de données.

TABLE 4.1 – Comparaison de l'apprentissage par renforcement et de l'IA générative

4.1.4 Choix de la méthode d'apprentissage pour le projet

Pour répondre efficacement à nos besoins spécifiques, nous avons opté pour l'apprentissage par renforcement comme méthode privilégiée. Cette décision est guidée principalement par la capacité de cette approche à gérer des données manquantes de manière dynamique, en adaptant continuellement le modèle en fonction des nouvelles informations reçues lors des interactions. L'apprentissage par renforcement excelle dans la création de modèles évolutifs capables de s'adapter aux comportements changeants des utilisateurs. En exploitant des récompenses et des pénalités à travers des expériences réitérées, le système apprend non seulement

à accomplir des tâches avec une efficacité accrue, mais également à s'ajuster aux nuances de comportement de chaque utilisateur. Cette adaptabilité en fait un choix optimal pour nos applications, où l'interaction utilisateur et la personnalisation sont essentielles.

4.1.5 Choix de l'algorithme d'apprentissage par renforcement

Face aux défis spécifiques de notre projet, nous avons choisi l'algorithme Q-learning pour l'apprentissage par renforcement. Cette méthode avancée est particulièrement adaptée pour gérer des environnements complexes où les agents doivent apprendre à optimiser leurs actions à partir d'une évaluation continue des récompenses obtenues. Voici les raisons principales qui justifient notre choix :

- **Adaptabilité aux environnements dynamiques** : Le Q-learning excelle dans les environnements où les états et les actions peuvent changer fréquemment. Cela est crucial pour notre application de fitness, où les programmes d'entraînement doivent s'adapter continuellement aux progrès et aux préférences de l'utilisateur.
- **Optimisation des récompenses** : En utilisant une stratégie d'exploration et d'exploitation, le Q-learning permet à l'agent d'apprendre quelles actions amènent aux meilleures récompenses à long terme. Cela assure une optimisation continue des séances d'entraînement, rendant chaque session plus efficace que la précédente.
- **Flexibilité et scalabilité** : Le Q-learning peut être facilement ajusté et étendu à des environnements plus complexes ou à des ensembles de données plus volumineux. Cette flexibilité nous permet de continuer à améliorer notre modèle au fur et à mesure que nous collectons davantage de données utilisateur.

Dans la figure ci-dessous, une illustration simple d'une grille 2x4 est présentée. Les coins supérieurs droits indiquent les récompenses pour chaque cellule et s montre les différents états dans lesquels on peut se trouver. Il est facile de voir quel chemin nous devrions prendre, mais pour notre agent, il doit apprendre à explorer notre environnement et à apprendre le chemin récompensé le plus optimal.




FIGURE 4.2 – Exemple d’un système de récompense simple.

4.2 Mathématiques du Q-learning

Cette section explore en détail l’aspect mathématique du Q-Learning, illustrant comment la fonction de valeur $Q(s, a)$ est calculée et exploitée pour orienter les décisions de l’agent vers la réalisation de ses objectifs. Comprendre cette formulation mathématique est vital pour saisir comment l’agent apprend de manière autonome à partir de son environnement. Cette capacité d’apprentissage autodidacte est particulièrement adaptée à notre application de fitness à domicile, où l’agent doit continuellement ajuster les programmes d’entraînement en réponse aux progrès et aux préférences de l’utilisateur.

Formule de la fonction de valeur $Q(s, a)$

La fonction de valeur, notée $Q(s, a)$, est exprimée comme suit[8] :

$$Q(s, a) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R_{t+1} \mid S_0 = s, A_0 = a \right] \quad (4.2.1)$$

où :

- \mathbb{E} représente l’espérance mathématique des récompenses futures.
- γ est le facteur de remise, qui pondère l’importance des récompenses obtenues dans les étapes futures.
- R_{t+1} est la récompense obtenue à l’étape $t + 1$.

-
- $S_0 = s$ et $A_0 = a$ indiquent que l'agent débute dans l'état s et prend l'action a .

Processus de mise à jour des valeurs Q

La mise à jour de la valeur Q se réalise via l'équation de Bellman, qui permet une révision itérative de la fonction basée sur les récompenses réellement obtenues et les estimations des meilleures actions futures :

Équation de Bellman pour Q-learning [9]

$$Q(s, a) = (1 - \epsilon)Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

Composantes de la formule :

- $Q(s, a)$: La valeur Q actuelle pour l'état s et l'action a .
- ϵ : Un paramètre qui contrôle la pondération entre la valeur Q actuelle et la mise à jour, il sert généralement dans l'exploration versus exploitation mais ici il semble agir comme un facteur de pondération pour la valeur actuelle lors de la mise à jour.
- α : Le taux d'apprentissage, qui détermine à quelle vitesse les estimations des valeurs Q sont ajustées.
- r : La récompense immédiate reçue après avoir pris l'action a dans l'état s .
- γ : Le facteur de remise, qui modère l'importance des récompenses futures.
- $\max_{a'} Q(s', a')$: La valeur Q maximale pour le prochain état s' et action a' , reflétant la meilleure récompense future attendue.
- $[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$: Le terme de mise à jour qui calcule la différence entre la récompense ajustée future et la valeur Q actuelle.

4.3 Exemple concret de calcul de la Q-table

Au début du processus, l'agent ne sait pas quelle action est meilleure qu'une autre. Ainsi, nous commençons par attribuer des estimations arbitraires à toutes les valeurs de Q et fixons toutes les entrées de la Q-table à 0. Observons un exemple de ce qui se passe au cours des premiers pas de temps pour visualiser comment la Q-table se remplit avec des valeurs réelles.

4.3.1 Premier pas de temps

Au premier pas de temps, l'agent choisit une action et met à jour la Q-table en conséquence. Par exemple, au premier pas de temps, l'état est $S1$ et l'action choisie est $a3$.

État initial :

$$Q(S1, a3) = 0$$

Mise à jour de la Q-table :

$$Q(S1, a3) = Q(S1, a3) + \alpha \left[R3 + \gamma \max_{a'} Q(S3, a') - Q(S1, a3) \right]$$

Prenons les valeurs suivantes pour simplifier le calcul :

- $\epsilon = 0$ (taux d'exploration)
- $\alpha = 1$ (taux d'apprentissage)
- $\gamma = 1$ (facteur de remise)
- $R3 = 4$ (récompense observée)

Ainsi, la mise à jour devient :

$$Q(S1, a3) = 0 + 1 [4 + 1 \cdot 0 - 0] = 4$$

État de la Q-table après mise à jour :

	Action 1	Action 2	Action 3	Action 4
S1	0	0	4	0
S3	0	0	0	0

4.3.2 Deuxième pas de temps

Au deuxième pas de temps, l'état est $S3$ et l'action choisie est $a1$.

État Initial :

$$Q(S3, a1) = 0$$

Mise à jour de la Q-table :

$$Q(S3, a1) = Q(S3, a1) + \alpha \left[R1 + \gamma \max_{a'} Q(S2, a') - Q(S3, a1) \right]$$

Prenons les valeurs suivantes pour simplifier :

- $\epsilon = 0$ (taux d'exploration)
- $\alpha = 1$ (taux d'apprentissage)
- $\gamma = 1$ (facteur de remise)
- $R1 = 2$ (récompense observée)

Ainsi, la mise à jour devient :

$$Q(S3, a1) = 0 + 1 [2 + 1 \cdot 0 - 0] = 2$$

État de la Q-table après mise à jour :

	Action 1	Action 2	Action 3	Action 4
S1	0	0	4	0
S2	0	0	0	0
S3	2	0	0	0

4.3.3 Troisième pas de temps

Au troisième pas de temps, l'état est $S1$ et l'action choisie est $a1$.

Etat initial :

$$Q(S1, a1) = 0$$

Mise à jour de la Q-table :

$$Q(S1, a1) = Q(S1, a1) + \alpha \left[R2 + \gamma \max_{a'} Q(S2, a') - Q(S1, a1) \right]$$

Prenons les valeurs suivantes pour simplifier :

- $\epsilon = 0$ (taux d'exploration)
- $\alpha = 1$ (taux d'apprentissage)
- $\gamma = 1$ (facteur de remise)
- $R2 = 3$ (récompense observée)

Ainsi, la mise à jour devient :

$$Q(S1, a1) = 0 + 1 [3 + 1 \cdot 0 - 0] = 3$$

État de la Q-table après mise à jour :

	Action 1	Action 2	Action 3	Action 4
S1	3	0	4	0
S2	0	0	0	0
S3	2	0	0	0

4.3.4 Quatrième pas de temps

Au quatrième pas de temps, l'état est $S2$ et l'action choisie est $a4$.

État Initial :

$$Q(S2, a4) = 0$$

Mise à jour de la Q-table :

$$Q(S2, a4) = Q(S2, a4) + \alpha \left[R4 + \gamma \max_{a'} Q(S3, a') - Q(S2, a4) \right]$$

Prenons les valeurs suivantes pour simplifier :

- $\epsilon = 0$ (taux d'exploration)
- $\alpha = 1$ (taux d'apprentissage)
- $\gamma = 1$ (facteur de remise)
- $R4 = 5$ (récompense observée)

Ainsi, la mise à jour devient :

$$Q(S2, a4) = 0 + 1 [5 + 1 \cdot 0 - 0] = 5$$

État de la Q-table après mise à jour :

	Action 1	Action 2	Action 3	Action 4
S1	3	0	4	0
S2	0	0	0	5
S3	2	0	0	0

Ainsi, nous voyons que la Q-table commence à se remplir avec des valeurs basées sur les récompenses observées, devenant progressivement plus précise à mesure que l'agent explore et exploite l'environnement.

Remarque : Comme vous pouvez l'observer, la mise à jour de la Q-table nécessite de nombreuses itérations pour se remplir complètement avec des valeurs significatives. L'implémentation sur des ordinateurs facilite ce processus, car ils peuvent effectuer ces calculs répétitifs et intensifs.

4.4 Modélisation du Q-learning à notre contexte

L'adaptation de l'algorithme Deep Q-Learning à notre système d'entraînement à domicile nécessite une compréhension claire de sa structure et de son fonctionnement. Cette section décrira la modélisation spécifique des états, actions, et récompenses conçus pour optimiser et personnaliser l'expérience utilisateur. En

adaptant l'algorithme à notre contexte spécifique, nous visons à maximiser l'efficacité des sessions d'entraînement tout en ajustant dynamiquement les programmes en fonction des réponses et des progrès des utilisateurs.

Définition des états : Les états dans le modèle représentent les informations cruciales sur la session d'entraînement en cours. Un état est défini par les éléments suivants :

- Programme d'entraînement actuel : identifie le programme spécifique suivi par l'utilisateur.
- Nombre de séances restantes : le nombre de séances restantes dans le programme actuel.
- Durée actuelle de la session : le temps total alloué pour la session en cours.
- Niveau de difficulté actuel : le niveau de difficulté des exercices dans la session actuelle.
- Progrès de la session : Le pourcentage du programme d'entraînement complété à ce moment.

Définition des actions : Les actions que l'agent peut choisir dans chaque état doivent être clairement définies pour permettre à l'agent de prendre des décisions efficaces basées sur l'apprentissage précédent. Dans notre cas, les actions disponibles pour l'agent incluent :

- Ajustement de la durée de la session :
 - Augmenter la durée : L'agent peut choisir d'augmenter la durée de la session d'entraînement par incréments de 1 minute, jusqu'à un maximum de 5 minutes supplémentaires.
 - Réduire la durée : L'agent peut également choisir de réduire la durée de la session par incréments de 1 minute, jusqu'à une réduction maximale de 5 minutes.
- Ajustement de la difficulté des exercices :
 - Augmenter la difficulté : cela pourrait signifier choisir des exercices classés à un niveau de difficulté plus élevé.
 - Réduire la difficulté : cela pourrait signifier choisir des exercices classés à un niveau de difficulté inférieur.

Codification des actions :

- Action 0 : ne pas changer la durée ni la difficulté.
- Actions 1 à 5 : augmenter la durée de 1 à 5 minutes.
- Actions 6 à 10 : réduire la durée de 1 à 5 minutes.

-
- Action 11 : augmenter la difficulté des exercices.
 - Action 12 : réduire la difficulté des exercices.

Définition de la fonction de récompense : La fonction de récompense est conçue pour optimiser et personnaliser l'expérience de l'utilisateur tout en maximisant l'efficacité des sessions d'entraînement. Elle évalue la performance de l'utilisateur, l'ajustement de la durée de la session et la pertinence de la difficulté des exercices ajustée par l'agent. La fonction de récompense est définie par plusieurs critères clés, chacun visant à encourager des comportements spécifiques qui soutiennent les objectifs globaux de formation :

- Critères de performance :
 - **Efficacité des exercices :** Récompense basée sur la proportion des répétitions effectuées par rapport aux répétitions cibles pour chaque exercice. Cela encourage l'utilisateur à atteindre ou dépasser les objectifs de performance pour chaque exercice inclus dans la session.
- Critères de durée :
 - **Ajustement de la durée :** Récompense ou pénalité appliquée en fonction de l'impact de l'ajustement de la durée sur le progrès de l'utilisateur. Si l'ajustement de la durée améliore le progrès de l'utilisateur, une récompense est accordée, si ce n'est pas le cas, une pénalité est imposée. Cette mesure vise non seulement à optimiser la gestion du temps pendant les sessions d'entraînement, mais également à encourager l'agent à modifier la durée de manière stratégique pour maximiser l'efficacité de l'entraînement en fonction de l'état de progression de l'utilisateur.
- Critères de difficulté :
 - **Ajustement de la difficulté :** Bonus ou malus basé sur l'adéquation de la difficulté des exercices avec le niveau de capacité actuel de l'utilisateur.

4.4.1 Fonctionnement de l'agent de fitness

L'agent que nous utilisons est comme un coach personnel intelligent et vise à améliorer de manière autonome les programmes d'entraînement de notre application de fitness à domicile. Voici son fonctionnement :

L'agent de fitness intelligent observe chaque séance d'entraînement et prend des notes sur divers aspects comme la durée, la difficulté et les progrès réalisés. En se basant sur ces observations, il décide d'ajuster le programme pour la prochaine séance d'entraînement. Les états que l'agent surveille incluent le programme d'entraînement actuel, le nombre de séances restantes, la durée de la séance, le niveau de difficulté et le progrès de la séance. Les actions qu'il peut prendre comprennent l'augmentation ou la réduction de la durée de la séance, ainsi que l'ajustement

de la difficulté des exercices. Après chaque séance, l'agent évalue la performance et ajuste ses décisions futures pour s'améliorer continuellement. Les récompenses sont attribuées en fonction de l'efficacité des exercices, de l'ajustement approprié de la durée et de la difficulté, visant à maximiser les résultats et la satisfaction des utilisateurs. En utilisant une stratégie d'exploration pour tester de nouvelles approches et une stratégie d'exploitation pour renforcer les meilleures pratiques, l'agent optimise constamment les séances d'entraînement.

L'exploration consiste à essayer de nouvelles actions pour découvrir leur effet, tandis que l'exploitation consiste à utiliser les actions déjà connues pour donner les meilleurs résultats. Cette combinaison permet à l'agent d'améliorer continuellement ses décisions en équilibrant innovation et optimisation.

4.4.2 Cas d'utilisation pour un utilisateur

Pour évaluer les performances de l'agent, nous avons analysé les ajustements réalisés par l'agent et les résultats obtenus au cours de plusieurs séances d'entraînement.

Interprétation des récompense par séances d'entraînement

Ce graphique montre l'évolution des récompenses totales obtenues par l'agent au cours des séances d'entraînement. Nous observons des variations significatives d'une séance à l'autre, indiquant que l'agent ajuste ses stratégies pour maximiser les récompenses basées sur la performance de l'utilisateur. Bien que l'agent soit en train d'apprendre, les fluctuations importantes dans les récompenses totales par séance d'entraînement indiquent qu'il y a encore de la place pour améliorer la stabilité et l'efficacité de l'apprentissage. Des ajustements dans les hyperparamètres et potentiellement des sessions d'entraînement supplémentaires peuvent être nécessaires pour atteindre une performance plus stable et optimisée.

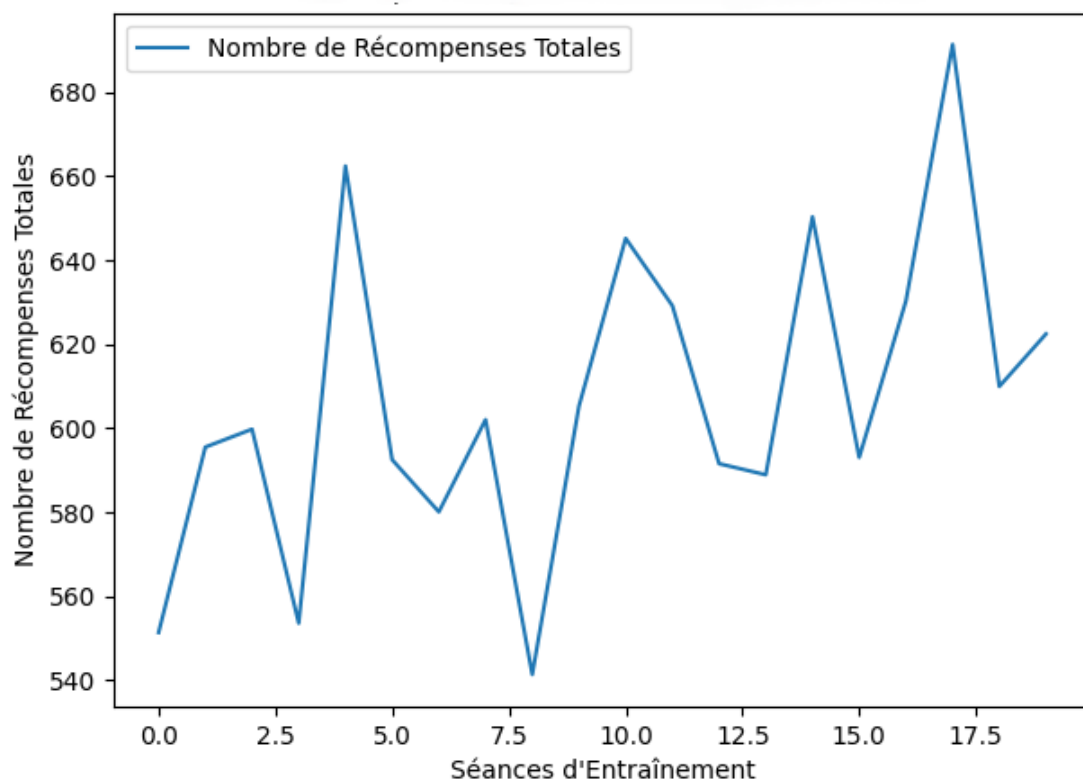


FIGURE 4.3 – Récompenses par séance d'entraînement.

Interprétation de la moyenne mobile des récompenses

La courbe de la moyenne mobile des récompenses montre que l'agent est globalement en train d'apprendre et d'améliorer ses performances. Les fluctuations initiales sont attendues dans le processus d'apprentissage par renforcement, car l'agent explore différentes actions. La tendance à la hausse indique que, malgré ces fluctuations, l'agent parvient à ajuster ses actions de manière à maximiser les récompenses au fil du temps. Pour améliorer encore la stabilité et la performance de l'agent, il pourrait être bénéfique de continuer à ajuster les hyperparamètres et à prolonger les sessions d'entraînement au besoin.




FIGURE 4.4 – Moyenne mobile des récompenses.

Interpretation de récompense moyenne cumulative par séance d'entraînement

Ce graphique montre la récompense moyenne cumulative par séance d'entraînement, offrant une vue d'ensemble des performances globales de l'agent sur la durée des simulations. Nous voyons une augmentation continue de la récompense moyenne cumulative, indiquant que l'agent devient de plus en plus efficace pour optimiser les séances d'entraînement de l'utilisateur.

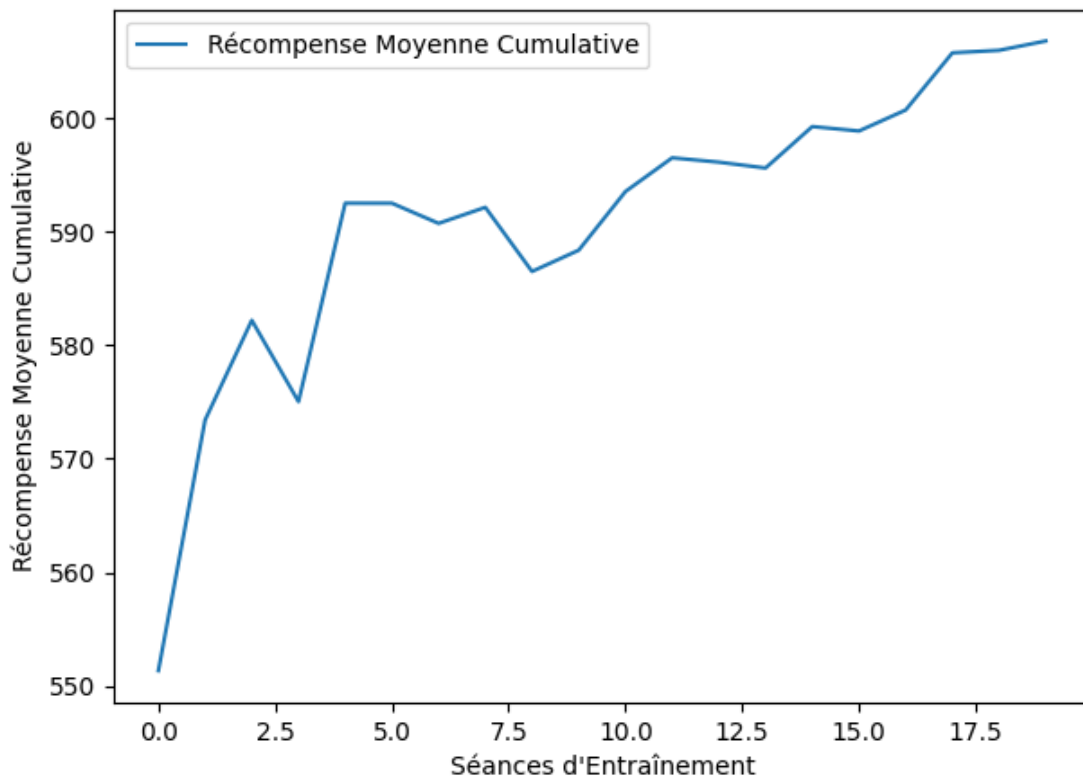


FIGURE 4.5 – Récompense moyenne cumulative par séance d'entraînement.

Interprétation d'epsilon

La courbe de décroissance d'Epsilon reflète un bon équilibre entre exploration et exploitation dans le processus d'apprentissage. En commençant par une phase d'exploration élevée, l'agent est en mesure de découvrir diverses actions et leurs conséquences. Au fur et à mesure que l'Epsilon diminue, l'agent utilise de plus en plus les connaissances acquises pour maximiser les récompenses en prenant des décisions plus informées. Cette approche progressive assure que l'agent apprend de manière efficace et devient plus performant au fil des séances.




FIGURE 4.6 – Décroissance d'epsilon au fil des séances.

Interpretation générale

Les courbes analysées montrent les tendances et les performances de l'agent de fitness au fil des séances d'entraînement. Pour améliorer encore l'apprentissage, il peut être utile de tester différentes valeurs initiales et taux de décroissance d'epsilon afin d'optimiser ce processus. De plus, ajuster le taux d'apprentissage (α) et le facteur de discount (γ) peut affiner la mise à jour des valeurs Q et améliorer l'efficacité de l'apprentissage. L'introduction de plus de diversité dans les programmes d'entraînement et les niveaux de difficulté permettra à l'agent de

s'adapter à une gamme plus large de situations, fournissant ainsi des recommandations plus personnalisées. Inclure des mécanismes de feedback direct de l'utilisateur aidera l'agent à s'ajuster rapidement aux préférences spécifiques et aux besoins de l'utilisateur. Ces stratégies contribueront à rendre l'apprentissage de l'agent plus robuste et à améliorer la qualité des programmes d'entraînement proposés, tout en assurant une expérience utilisateur optimisée et personnalisée.

Conclusion

Dans ce chapitre, nous avons terminé la phase de modélisation de notre projet en appliquant l'algorithme de Q-Learning à notre système d'entraînement à domicile. Nous avons commencé par une introduction aux concepts théoriques de l'apprentissage par renforcement, puis nous avons détaillé la mise en œuvre de l'algorithme de Q-Learning pour notre contexte spécifique. Des exemples concrets de mise à jour de la Q-table ont été fournis pour illustrer le processus d'apprentissage. Les résultats de l'évaluation, y compris les courbes de performance, ont démontré l'efficacité de l'agent dans l'optimisation des séances d'entraînement.

Conclusion et perspective

Ce projet a abouti à la création d'un agent de fitness intelligent utilisant des techniques d'apprentissage automatique pour optimiser et personnaliser les séances d'entraînement à domicile. Nous avons exploré et comparé deux approches d'intelligence artificielle, l'apprentissage par renforcement et l'intelligence artificielle générative, et nous avons opté pour l'algorithme Q-Learning en raison de son efficacité dans des environnements complexes. Nous avons détaillé la modélisation mathématique de l'algorithme et son application à notre contexte spécifique. Nos résultats montrent que l'agent peut surveiller les séances d'entraînement, évaluer les performances, et ajuster les programmes en fonction des besoins évolutifs des utilisateurs, améliorant ainsi significativement leur expérience d'entraînement.

L'objectif principal de ce projet était de développer un système capable d'optimiser et de personnaliser les séances d'entraînement des utilisateurs à domicile en utilisant des techniques d'apprentissage automatique. Nous avons réussi à atteindre cet objectif en créant un agent capable d'adapter dynamiquement les programmes d'entraînement en fonction des données collectées sur les performances des utilisateurs. En intégrant des algorithmes avancés, l'agent peut désormais ajuster les séances d'entraînement pour maximiser les résultats et la satisfaction des utilisateurs.

Notre étude a rencontré plusieurs défis, notamment le manque de données historiques suffisants pour entraîner les modèles d'intelligence artificielle. Nous avons surmonté cette contrainte en mettant en place des méthodes de génération de données pour simuler les conditions réelles. Cependant, l'utilisation de données générées peut introduire des biais et limiter la généralisation des résultats. De plus, l'optimisation des hyperparamètres et la validation des modèles nécessitent des ressources computationnelles importantes, ce qui peut être une contrainte dans des environnements avec des ressources limitées.

Les résultats obtenus laissent place à des travaux futurs pour améliorer encore le système. Nous envisageons d'intégrer des modèles d'IA générative pour enrichir

l'expérience utilisateur, permettant aux utilisateurs de poser des questions sur la nutrition et les entraînements pour obtenir des conseils personnalisés. Inclure des mécanismes de feedback direct de l'utilisateur pour que l'agent puisse s'ajuster rapidement aux préférences spécifiques et aux besoins de chaque utilisateur rendra l'apprentissage de l'agent plus robuste et améliorera la qualité des programmes d'entraînement proposés. De plus, segmenter les utilisateurs ayant des objectifs ou des caractéristiques similaires permettront à l'agent de prendre des décisions plus précises et ciblées, augmentant ainsi l'efficacité des séances d'entraînement.

Avec ces perspectives, nous visons à améliorer continuellement notre agent de fitness intelligent pour offrir une expérience utilisateur optimale et personnalisée, permettant à nos utilisateurs de s'entraîner avec AIMOOV et de bénéficier d'un coach basé sur l'IA.

En conclusion, ce projet m'a permis de cumuler des connaissances théoriques et pratiques, et de découvrir le milieu professionnel dans un environnement motivant et soutenant. Je suis satisfait des compétences acquises et des résultats obtenus.

Bibliographie

- [1] Aimooov : Caméra de fitness intelligente. Consulté le 5 mars, 2024. URL : <https://ai-bright.com/>.
- [2] Apprentissage par renforcement : Concepts et applications. Consulté le 3 mai, 2024. URL : <https://www.spiceworks.com/tech/artificial-intelligence/articles/what-is-reinforcement-learning/>.
- [3] Crisp-dm : Processus standard pour l'exploration de données. Consulté le 20 mars, 2024. URL : <https://www.ibm.com/docs/fr/spss-modeler/saas?topic=dm-crisp-help-overview>.
- [4] Fichier json : Structure et utilisation. Consulté le 25 mars, 2024. URL : <https://www.json.org/json-en.html>.
- [5] Fréquence cardiaque maximale : Définition et calcul. Consulté le 20 mars, 2024. URL : https://fr.wikipedia.org/wiki/Fr%C3%A9quence_cardiaque_maximale.
- [6] Intelligence artificielle générative : Explications et applications. Consulté le 1 mai, 2024. URL : <https://news.mit.edu/2023/explained-generative-ai-1109>.
- [7] Kdd : Processus de découverte de connaissances en bases de données. Consulté le 20 mars, 2024. URL : <https://medium.com/@shawn.chumbar/kdd-process-in-data-science-a-beginners-guide-426d1f0fc062>.
- [8] La fonction de valeur $q(s, a)$: Calcul et utilisation. Consulté le 17 mai, 2024. URL : <https://medium.com/@devarakonda.vishnu5/simple-deep-q-learning-with-math-1afb0cfdcf0d>.
- [9] L'équation de bellman : Théorie et pratique. Consulté le 17 mai, 2024. URL : <https://ai.plainenglish.io/deep-q-learning-understanding-the-math-behind-the-magic-9ab03d893baf>.
- [10] Pouls au repos chez les hommes et les femmes : Références par âge et condition physique. Consulté le 20 mars, 2024. URL : <https://flexikon.doccheck.com/de/Herzfrequenz>.

-
- [11] Semma : Méthodologie pour l'exploration et la modélisation des données. Consulté le 20 mars, 2024. URL : <https://www.datascience-pm.com/semma/>.
 - [12] Site officiel de discord. Consulté le 1 mars, 2024. URL : <https://discord.com/company>.
 - [13] Site officiel de git. Consulté le 30 mars, 2024. URL : <https://git-scm.com/>.
 - [14] Site officiel de google colab. Consulté le 25 mars, 2024. URL : <https://research.google.com/colaboratory/faq.html?hl=fr>.
 - [15] Site officiel de python. Consulté le 8 avril, 2024. URL : <https://www.python.org/>.
 - [16] Zones de fréquence cardiaque : Méthodes de calcul et applications. Consulté le 25 mars, 2024. URL : <https://health.clevelandclinic.org/exercise-heart-rate-zones-explained>.